

ChatGPT는 어떻게 사람처럼 말할까?

AI는 스스로 '생각'해서
대답하는 것이 아닙니다.
주어진 문장 뒤에 이어질
가장 자연스러운 말을
수학적인 패턴으로 예측할 뿐입니다.




LLM은 다음 토큰을 예측하는 확률 기계

대규모 언어 모델(LLM)은 방대한 글의 패턴을 학습하여, 다음 빈칸에 들어갈 가장 확률이 높은 조각을 예측합니다.



텍스트를 AI가 소화할 수 있게 자르기: 토큰화

AI는 글자를 그대로 이해하지 못하므로, 문장을 의미가 있는 작은 조각인 '토큰(Token)'으로 나눕니다.



토큰에 위치 달아주기: 벡터와 임베딩


쪼개진 토큰들은 AI의 거대한
3차원 의미 공간에서
비슷한 의미끼리 모여 있는
‘숫자 좌표(벡터)’로 변환됩니다.

단어들이 서로의 의미적 거리에 따라
우주 공간의 별자리처럼 배치됩니다.



언어의 규칙을 직접 코딩하기 어려운 이유

언어에는 예외가 너무 많고 문맥에 따라 뜻이 변해서,
사람이 직접 '이럴 땐 이렇게 대답해'라는 규칙을 프로그래밍하는 것은 불가능합니다.



규칙을 직접 코딩하는 방식은 곧 한계에 부딪혔습니다.
스스로 패턴을 학습하는 언어 모델이 필요해진 이유입니다.

AI 내부의 수많은 조절 다이얼 : 파라미터

규칙을 직접 짜는 대신, AI는 수백억 개의 '파라미터'라는 다이얼을 돌리면서 언어의 패턴을 스스로 맞춰 나갑니다.



긴 문맥을 한꺼번에 보기: 트랜스포머

과거 AI는 단어를 하나씩 순서대로 읽었지만, 트랜스포머는 문장 전체를 병렬로 한꺼번에 파악하여 처리 속도와 이해도를 획기적으로 높였습니다.

과거의 모델



단어를 하나씩 순서대로 처리


트랜스포머 모델



전체 문장을 한눈에 병렬로 처리

중요한 단어를 찾아 연결하기: 어텐션 (Attention)

트랜스포머 내부에는 문장 안에서 서로 깊은 관련이 있는 단어들을 수학적으로 찾아 연결해 주는 ‘어텐션’이라는 기술이 있습니다.



문맥에 따라 달라지는 단어의 의미


어텐션 형광펜 덕분에, 똑같은 단어라도 주변에 어떤 단어가 있는지에 따라 AI가 받아들이는 의미(벡터 좌표)가 다르게 조정됩니다.



어텐션은 주변 단어들을 살펴보고 단어의 의미 좌표를 적절한 위치로 이동시킵니다.

끝없이 오답을 고치는 과정: 학습 (Training)

AI는 예측하고 정답과 비교한 뒤, 오차가 작아지도록 수백억 개의 파라미터 다이얼을 수정하는 과정을 반복합니다.



막대한 데이터와 GPU가 필요한 이유

인터넷 전체 수준의 텍스트로 오답노트를 반복하려면
엄청난 연산량이 필요해 초고속 특수 칩(GPU)이 필수적입니다.

일반 컴퓨터 / 사람의 속도

사람이 읽는다면
쉬지 않고 2,600년 소요



GPU 공장

수천 개의 초고속
병렬 처리 벨트 (GPU)



점수에서 확률로: Logits와 Softmax

AI가 내놓은 후보 단어들의 원시 점수(Logits)는 'Softmax'라는 변환 과정을 거쳐 전체 합이 100%가 되는 확률로 바뀝니다.



창의성 조절 장치: Temperature (온도)

항상 1등 확률만 고르면 답변이 뻔해집니다.

Temperature를 높여 가끔 2, 3등 후보도 고르게 하면 AI의 창의성이 살아납니다.



사람의 입맛에 맞게 다듬기: RLHF

거친 인터넷 글을 배운 AI가 친절하고 안전한 답변을 하도록,
사람이 직접 좋은 답변을 골라주며 훈련시킵니다.

거친 인터넷 학습 상태



거친 말,
위험한 정보

RLHF 피드백 후



칭찬 점수 / Reward

친절하고
안전한 답변

사람 피드백 기반 강화학습(RLHF)을 통해
AI는 비로소 우리가 아는 친절한 어시스턴트가 됩니다.

마법이 아니라 수학과 데이터의 결정체

